Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования «Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра ИУ5 «Системы обработки информации и управления»

Курс «Технологии машинного обучения»

Лабораторная работа №2

Выполнил:
студент группы ИУ5-63Б
Комаров Д. С.

Проверил:
Гапанюк Ю. Е.

2024 г.

Задание

Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.) Просьба не использовать датасет, на котором данная задача решалась в лекции. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи: устранение пропусков в данных; кодирование категориальных признаков; нормализация числовых признаков.

Ход работы:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.impute import SimpleImputer
%matplotlib inline
sns.set(style="ticks")

data_loaded = pd.read_csv('sample_data/crimes.csv', sep=",")

# размер набора данных
data_loaded.shape
```

```
(25648, 12)
```

```
data_loaded.head()
```


```
{"summary":"{\n  \"name\": \"data_loaded\",\n  \"rows\": 25648,\n
\"fields\": [\n    {\n      \"column\": \"CrimeDate\",\n
\"properties\": {\n        \"dtype\": \"object\",\n
\"num_unique_values\": 186,\n        \"samples\": [\n
\"07/26/2016\",\n          \"06/05/2016\",\n          \"05/31/2016\"\n
],\n        \"semantic_type\": \"\",\n        \"description\": \"\"\n
}\n    },\n    {\n      \"column\": \"CrimeTime\",\n      \"properties\":
{\n        \"dtype\": \"category\",\n        \"num_unique_values\":
1904,\n        \"samples\": [\n          \"06:29:00\",\n
\"21:10:00\",\n          \"04:16:00\"\n        ],\n
\"semantic_type\": \"\",\n        \"description\": \"\"\n      }\n    },\n
{\n      \"column\": \"CrimeCode\",\n      \"properties\": {\n
\"dtype\": \"category\",\n        \"num_unique_values\": 74,\n
\"samples\": [\n          \"4E\",\n          \"1O\",\n          \"5B\"\n
],\n        \"semantic_type\": \"\",\n        \"description\": \"\"\n
}\n    },\n    {\n      \"column\": \"Location\",\n      \"properties\":
{\n        \"dtype\": \"category\",\n        \"num_unique_values\":
9446,\n        \"samples\": [\n          \"1100 CAMBRIA ST\",\n
\"2800 GREENMOUNT AV\",\n          \"400 E BELVEDERE AVE\"\n        ],\n
\"semantic_type\": \"\",\n        \"description\": \"\"\n      }\n    },\n
{\n      \"column\": \"Description\",\n      \"properties\": {\n
\"dtype\": \"category\",\n        \"num_unique_values\": 15,\n
\"samples\": [\n          \"ASSAULT BY THREAT\",\n
\"HOMICIDE\",\n          \"ROBBERY - STREET\"\n        ],\n
\"semantic_type\": \"\",\n        \"description\": \"\"\n      }\n    },\n
{\n      \"column\": \"Inside/Outside\",\n      \"properties\": {\n
```

\"dtype\": \"category\",\n   \"num_unique_values\": 4,\n
\"samples\": [\n   \"I\",\n   \"Inside\",\n   \"O\"\n
],\n   \"semantic_type\": \"\",\n   \"description\": \"\"\n
}\n   },\n   {\n   \"column\": \"Weapon\",\n   \"properties\": {\n
\"dtype\": \"category\",\n   \"num_unique_values\": 4,\n
\"samples\": [\n   \"HANDS\",\n   \"KNIFE\",\n
\"FIREARM\"\n   ],\n   \"semantic_type\": \"\",\n
\"description\": \"\"\n   }\n   },\n   {\n   \"column\":
\"Post\",\n   \"properties\": {\n   \"dtype\": \"number\",\n
\"std\": 268.0528927926924,\n   \"min\": 0.0,\n   \"max\":
944.0,\n   \"num_unique_values\": 147,\n   \"samples\": [\n
0.0,\n   113.0,\n   314.0\n   ],\n
\"semantic_type\": \"\",\n   \"description\": \"\"\n   }\n   },\n
{\n   \"column\": \"District\",\n   \"properties\": {\n
\"dtype\": \"category\",\n   \"num_unique_values\": 12,\n
\"samples\": [\n   \"SOUTHESTERN\",\n   \"NORTHESTERN\",\n
\"CENTRAL\"\n   ],\n   \"semantic_type\": \"\",\n
\"description\": \"\"\n   }\n   },\n   {\n   \"column\":
\"Neighborhood\",\n   \"properties\": {\n   \"dtype\":
\"category\",\n   \"num_unique_values\": 277,\n   \"samples\":
[\n   \"Howard Park\",\n   \"Cylburn\",\n   \"Wyman
Park\"\n   ],\n   \"semantic_type\": \"\",\n
\"description\": \"\"\n   }\n   },\n   {\n   \"column\":
\"Location 1\",\n   \"properties\": {\n   \"dtype\": \"string\",\n
\"num_unique_values\": 17126,\n   \"samples\": [\n
\"(39.3582600000, -76.6016000000)\",\n   \"(39.3424100000,
-76.6827200000)\",\n   \"(39.2867600000, -76.5633500000)\"\n
],\n   \"semantic_type\": \"\",\n   \"description\": \"\"\n
}\n   },\n   {\n   \"column\": \"Total Incidents\",\n
\"properties\": {\n   \"dtype\": \"number\",\n   \"std\": 0.0,\n
\"min\": 1.0,\n   \"max\": 1.0,\n   \"num_unique_values\": 1,\n
\"samples\": [\n   1.0\n   ],\n   \"semantic_type\":
\"\",\n   \"description\": \"\"\n   }\n   }\n
]\n}","type":"dataframe","variable_name":"data_loaded"}

```
# Создаем список, содержащий признаки, их типы данных и количество пропусков
data_features = list(zip(
    # Признаки
    [i for i in data_loaded.columns],
    zip(
        # Типы колонок
        [str(i) for i in data_loaded.dtypes],
        # Проверим, есть ли пропущенные значения, и вычислим их процентное соотношение к общему количеству данных
        [i for i in data_loaded.isnull().sum()],
        # Процентное соотношение пропущенных значений к общему количеству данных
        [(i / len(data_loaded)) * 100 for i in data_loaded.isnull().sum()]
    )
))
# Выводим признаки с типом данных, количеством пропусков и их процентным соотношением к общему количеству данных
data_features
```

```
[('CrimeDate', ('object', 0, 0.0)),
 ('CrimeTime', ('object', 0, 0.0)),
 ('CrimeCode', ('object', 1, 0.003898939488459139)),
 ('Location', ('object', 104, 0.40548970679975044)),
 ('Description', ('object', 1, 0.003898939488459139)),
 ('Inside/Outside', ('object', 93, 0.36260137242669993)),
 ('Weapon', ('object', 16485, 64.27401746724891)),
 ('Post', ('float64', 8, 0.031191515907673113)),
 ('District', ('object', 8, 0.031191515907673113)),
 ('Neighborhood', ('object', 113, 0.44058016219588275)),
 ('Location 1', ('object', 101, 0.3937928883343731)),
 ('Total Incidents', ('float64', 1, 0.003898939488459139))]
```

```
# проверим есть ли пропущенные значения
data_loaded.isnull().sum()
```

```
CrimeDate              0
CrimeTime              0
CrimeCode              1
Location             104
Description            1
Inside/Outside        93
Weapon             16485
Post                   8
District               8
Neighborhood         113
Location 1           101
Total Incidents        1
dtype: int64
```

```
data = data_loaded

# удалим значения
data.dropna(subset=['CrimeCode', 'District', 'Location'], inplace=True)

imp = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp_df = pd.DataFrame(data=data_imp, columns=['Weapon'])

data['Weapon'] = data_imp_df['Weapon']

# Создаем список, содержащий признаки, их типы данных и количество
пропусков
data_features = list(zip(
    # Признаки
    [i for i in data_loaded.columns],
    zip(
        # Типы колонок
        [str(i) for i in data_loaded.dtypes],
        # Проверим, есть ли пропущенные значения, и вычислим их
процентное соотношение к общему количеству данных
        [i for i in data_loaded.isnull().sum()],
        # Процентное соотношение пропущенных значений к общему
количеству данных
        [(i / len(data_loaded)) * 100 for i in data_loaded.isnull().sum()]
    )
```

```
))
# Выводим признаки с типом данных, количеством пропусков и их процентным соотношением к общему количеству данных
data_features
```

```
[('CrimeDate', ('object', 0, 0.0)),
 ('CrimeTime', ('object', 0, 0.0)),
 ('CrimeCode', ('object', 0, 0.0)),
 ('Location', ('object', 0, 0.0)),
 ('Description', ('object', 0, 0.0)),
 ('Inside/Outside', ('object', 91, 0.35624804259317255)),
 ('Weapon', ('object', 103, 0.4032258064516129)),
 ('Post', ('float64', 0, 0.0)),
 ('District', ('object', 0, 0.0)),
 ('Neighborhood', ('object', 12, 0.04697776385844034)),
 ('Location 1', ('object', 0, 0.0)),
 ('Total Incidents', ('float64', 0, 0.0))]
```

кодирование категориальных признаков;

```
# Выбран кодовый формат
```

One-hot encoding предполагает, что значение категории заменяется на отдельную колонку, которая содержит бинарные значения.

```
dummies = pd.get_dummies(data[['Weapon']])

dummies = dummies.astype(int)

print(dummies.head())
```

```
   Weapon_FIREARM  Weapon_HANDS  Weapon_KNIFE  Weapon_OTHER
0               0             1             0             0
1               1             0             0             0
2               0             1             0             0
3               0             1             0             0
4               0             1             0             0
```

Масштабирование;

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['Post']])
plt.hist(data['Post'], 50)
plt.show()
```

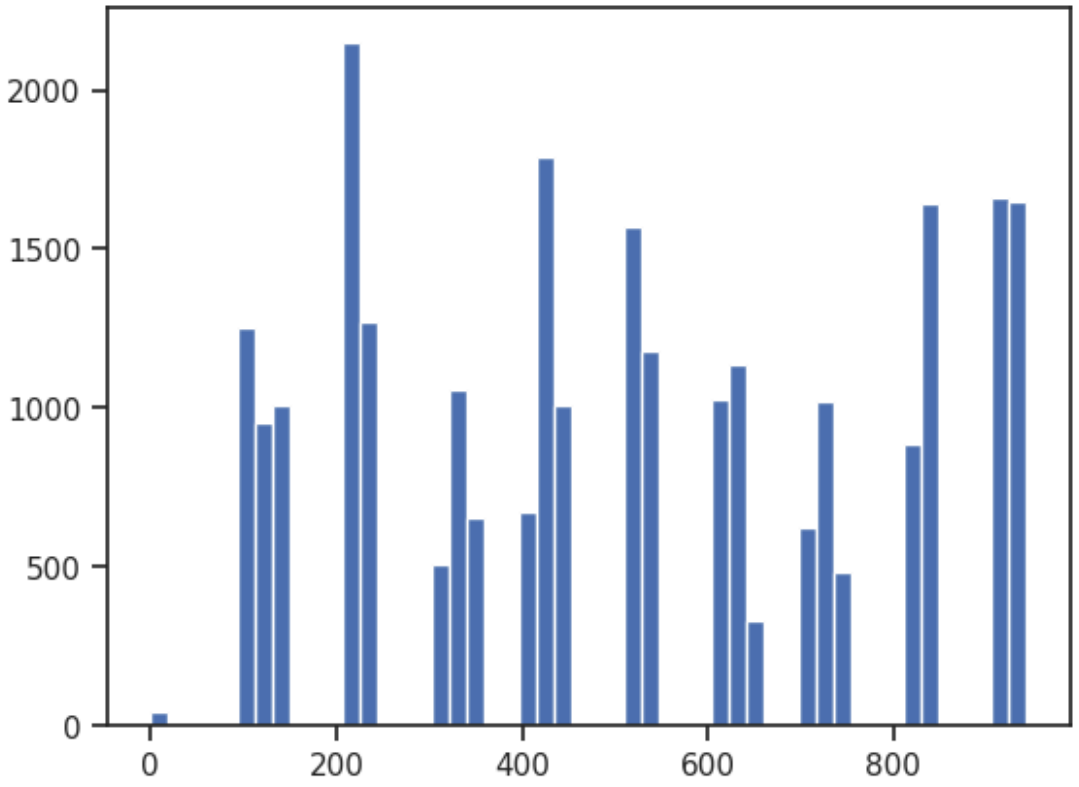


```
plt.hist(sc1_data, 50)
plt.show()
```